

FAKULTET ZA INFORMACIONE SISTEME I TEHNOLOGIJE

INFORMACIONI SISTEMI ZA PODRŠKU ODLUCIVANJU

ZAVRŠNI PROJEKAT

Segmentacija kupaca pomoću mašinskog učenja

RFM analiza i K-Means klasterovanje u e-commerce okruženju

Mentor: Mr Milica Janković

Student: Luka Tačić 23/101

Podgorica, jun 2026. godine

Sadržaj

1. UVOD.....	3
2. PROBLEM I CILJ PROJEKTA.....	3
3. PODACI I ULAZ U SISTEM.....	4
4. METODOLOGIJA: RFM ANALIZA.....	5
5. K-MEANS KLASTEROVANJE.....	6
6. WEB APLIKACIJA I LIVE DEMO.....	7
7. REZULTATI I INTERPRETACIJA.....	8
8. PODRŠKA ODLUČIVANJU.....	9
9. TEHNOLOGIJE I IMPLEMENTACIJA.....	10
10. ZAKLJUČAK.....	11

1. UVOD

Ovaj rad predstavlja praktični Data Mining projekat za e-commerce okruženje. Glavna ideja je da se podaci o kupovini iskoriste za automatsku segmentaciju kupaca, odnosno za razumijevanje različitih tipova korisnika kroz RFM analizu i K-Means klasterovanje.

Projekat nije zamišljen samo kao tehnička vježba, već kao alat koji menadžmentu može da pomogne pri donošenju odluka. Umjesto da kompanija svim kupcima šalje iste poruke i iste popuste, sistem pokazuje koje grupe kupaca postoje i kakav pristup je najpogodniji za svaku grupu.

2. PROBLEM I CILJ PROJEKTA

Problem: e-commerce kompanija ima veliki broj kupaca, ali se marketing često sprovodi kao da su svi korisnici isti. Isti email, isti popust i isti pristup ne mogu dati najbolji rezultat, jer kupci imaju različite navike, vrijednost i rizik od odlaska.

Cilj projekta je da se napravi jednostavan alat koji automatski izdvaja segmente kupaca i prikazuje rezultate kroz razumljiv dashboard. Na taj način se podaci o kupovini pretvaraju u konkretnu osnovu za personalizovane kampanje, bolje zadržavanje korisnika i racionalnije trošenje marketing budžeta.

3. PODACI I ULAZ U SISTEM

Aplikacija je napravljena tako da korisnik može da učitava CSV fajl sa osnovnim transakcionim podacima. U trenutnoj implementaciji, za rad sistema su potrebne tri kolone: identifikator kupca, datum kupovine i iznos kupovine. To je dovoljno da se izračunaju Recency, Frequency i Monetary vrijednosti.

Tabela 1: Minimalni ulazni podaci za RFM analizu

Kolona	Značenje	Primjer
CustomerID	Jedinstveni identifikator kupca	101
InvoiceDate	Datum kada je kupovina izvršena	2026-01-10
Amount	Vrijednost kupovine u novcu	150.00

Na osnovu ovih podataka sistem računa koliko je kupac skoro kupovao, koliko često kupuje i koliko ukupno troši. U realnom poslovnom okruženju isti pristup se može proširiti dodatnim kolonama, kao što su kategorija proizvoda, kanal prodaje, kampanja i lokacija kupca.

Za demonstraciju projekta koristi se testni fajl podaci.csv. On je mali, ali je dovoljan da se na odbrani jasno pokaže kompletan tok rada: upload podataka, izračunavanje RFM vrijednosti, dodjela klastera i prikaz rezultata u aplikaciji.

4. METODOLOGIJA: RFM ANALIZA

RFM je jednostavan, ali veoma koristan model za razumijevanje kupaca. Umjesto da se posmatra samo ukupan broj kupovina, RFM istovremeno posmatra svježinu kupovine, učestalost kupovine i ukupnu novčanu vrijednost kupca.

Tabela 2: Objašnjenje RFM modela

Mjera	Puni naziv	Šta mjeri	Poslovno značenje
R	Recency	Broj dana od posljednje kupovine	Niža vrijednost znači aktivniji kupac
F	Frequency	Broj kupovina kupca	Veća vrijednost znači veću lojalnost
M	Monetary	Ukupna potrošnja kupca	Veća vrijednost znači veću finansijsku vrijednost

U implementaciji se Recency računa kao razlika između najnovijeg datuma u datasetu i posljednje kupovine svakog kupca. Frequency se dobija brojanjem kupovina po kupcu, dok se Monetary dobija sabiranjem svih iznosa kupovina.

Prednost RFM pristupa je u tome što je razumljiv i ljudima koji nijesu tehnički eksperti. Zbog toga je pogodan za menadžerski dashboard, jer rezultat nije samo matematički model, već praktična priča o ponašanju kupaca.

5. K-MEANS KLASTEROVANJE

Nakon RFM proračuna, sistem koristi K-Means algoritam kako bi automatski grupisao kupce sa sličnim ponašanjem. U trenutnoj verziji implementacije koristi se $K = 3$, što daje tri osnovna segmenta kupaca i omogućava jasnu interpretaciju rezultata.

End-to-end pipeline segmentacije kupaca




Slika 1: Pipeline od učitavanja podataka do poslovne odluke

Tabela 3: Poslovna interpretacija mogućih klastera


Segment	Tipično ponašanje	Primjer marketinške akcije
Loyal / high-value buyers	Često kupuju i imaju visoku ukupnu potrošnju	Premium ponude, early access, loyalty program
Novi / aktivni kupci	Nedavno su kupovali, ali još nemaju dugu istoriju	Welcome kampanja i personalizovane preporuke
Kupci koji odlaze	Dugo nijesu kupovali ili imaju nižak angažman	Win-back email, kupon za povratak, podsjetnik

6. WEB APLIKACIJA I LIVE DEMO

Aplikacija je razvijena u Python-u pomoću Streamlit framework-a. Korisnik učitava fajl, sistem automatski izračuna RFM vrijednosti, pokrene K-Means i prikaže rezultate kroz tabele i interaktivni grafički prikaz.



Slika 2: Prvi dio live demo-a u pokrenutoj Streamlit aplikaciji




Slika 3: Drugi dio live demo-a i prikaz klastera na grafiku

7. REZULTATI I INTERPRETACIJA

Na testnim podacima sistem dobija RFM tabelu i dodjeljuje klaster svakom kupcu. Iako je dataset mali i koristi se za demonstraciju, logika rada je ista i za veće skupove podataka iz realne e-commerce kompanije.

Tabela 4: Primjer RFM rezultata na testnim podacima

CustomerID	Recency	Frequency	Monetary	Klaster
101	32	2	350.00	0
102	12	2	380.50	0
103	3	2	350.00	0
104	1	2	950.75	1
105	0	2	210.00	2



Slika 4: Prosječna potrošnja po segmentu

Interpretacija rezultata omogućava da se kupci ne posmatraju samo kao redovi u tabeli, već kao grupe sa različitim ponašanjem i različitim poslovnim potencijalom.

8. PODRŠKA ODLUČIVANJU

Najvažnija vrijednost projekta nije samo to što algoritam napravi klastere, već to što menadžment dobija osnovu za različite marketinške akcije. Svaki segment može imati poseban pristup, posebnu poruku i poseban cilj.

Tabela 5: Marketing playbook po segmentima

Segment	Cilj	Preporučena akcija	Očekivani efekat
Visoka vrijednost	Zadržavanje najboljih kupaca	VIP ponude, early access, loyalty program	Veći CLV i jača lojalnost
Aktivni kupci	Povećanje učestalosti kupovine	Personalizovane preporuke i cross-sell	Veća prosječna vrijednost kupovine
Rizični kupci	Povratak kupaca koji odlaze	Win-back kampanja i vremenski ograničen popust	Smanjenje churn-a

Ovakav pristup podržava odlučivanje jer marketing tim više ne mora da pogađa kome treba poslati koju ponudu. Umjesto jednog univerzalnog pristupa, dobija se segmentisani pristup koji je precizniji i lakše mjerljiv.

9. TEHNOLOGIJE I IMPLEMENTACIJA

Projekat je razvijen kao jednostavna web aplikacija koja se može pokrenuti lokalno ili deploy-ovati na platforme koje podržavaju Streamlit. Struktura projekta je jasna: app.py sadrži aplikacionu logiku, podaci.csv služi za demo, a requirements.txt navodi potrebne biblioteke.

Tabela 6: Tehničke komponente projekta

Komponenta	Tehnologija	Uloga u projektu
Programski jezik	Python	Glavna logika aplikacije i obrada podataka
Web interfejs	Streamlit	Upload fajla, prikaz tabela i dashboarda
Obrada podataka	Pandas	Čitanje CSV-a, grupisanje i RFM proračun
Model	Scikit-learn / K-Means	Automatsko klasterovanje kupaca
Vizualizacija	Plotly	Interaktivni grafički prikaz segmenata

Pokretanje aplikacije je jednostavno: instaliraju se zavisnosti iz requirements.txt fajla i pokreće se Streamlit aplikacija.

10. ZAKLJUČAK

Projekat pokazuje kako se osnovne Data Mining tehnike mogu primijeniti na realan poslovni problem e-commerce kompanije. Sistem automatski učitava podatke, računa RFM vrijednosti, pokreće K-Means klasterovanje i prikazuje rezultate kroz web aplikaciju.

Najveća vrijednost projekta je u tome što se tehnički rezultat pretvara u poslovnu odluku. Segmenti kupaca omogućavaju personalizovan marketing, bolje zadržavanje korisnika i efikasniju raspodjelu budžeta.

„Cilj nije samo da algoritam podijeli kupce, već da kompanija iz tih grupa zna šta konkretno treba da uradi.”

Hvala na pažnji!